내 연구 이해하기

Where Aid Lands: Roads, Connectivity, or Need?
방법론 학습 노트: OLS에서 출발해 우리 연구의 모든 식까지

> **이 노트의 목표**
> 수식을 증명하는 것이 아니라, 우리 연구에 나오는 식 하나하나가 **무엇을 의미하는지** 직관적으로 이해하고, 결과 숫자를 **어떻게 읽는지**, 심사자가 물으면 **어떻게 답하는지**까지 가는 것입니다.

출발점: 경제통계학, 그리고 계량경제학의 OLS와 단순회귀모형(SLRM). 여기서 한 걸음씩 넓혀 갑니다.

각 장의 구성: ① 한 줄 요약 → ② 이미 아는 것에서 출발 → ③ 우리 연구의 식과 기호 풀이 → ④ 우리 숫자로 읽기 → ⑤ 흔한 오해 → ⑥ 심사자 질문

권장 진도: 하루 한 장, 약 3주. 맨 뒤에 자가 점검 문제와 용어집이 있습니다.

장	내용	핵심 질문
0	큰 그림	우리 연구는 무엇을 물었고 무엇을 찾았나
1–2	OLS와 다중회귀 (복습 + 확장)	도로가 좋으면 사업이 몇 개 더 오나
3	고정효과	왜 같은 주끼리만 비교하나
4	표준화 (1SD)	'1표준편차당'이 무슨 뜻인가
5	PPML: 개수를 위한 회귀	왜 OLS 대신 지수 모형인가, +165%는 어떻게 나오나
6–7	표준오차와 소수 군집 보정 3+1종	결과가 우연이 아니라고 어떻게 확신하나
8–9	다중공선성, 경합 모형, Shapley	빈곤과 도로 중 누가 설명하나
10	주성분 지수	물리적 접근성 숫자는 어떻게 만들었나
11	사건연구	인프라가 원조를 끌어오나
12–13	경계·민감도·투 트랙	결과가 가정에 얼마나 민감한가
14–16	심사자 Q&A, 학습 계획, 퀴즈, 용어집	실전 대비

0장

큰 그림: 우리 연구 한 장 요약

질문. 원조는 가장 가난한 곳으로 가는가, 아니면 가장 닿기 쉬운 곳으로 가는가? '닿기 쉽다'를 세 가지로 나눴습니다: 도로(물리적 접근성), 통신(디지털 접근성), 경제활동(야간 불빛).

자료. 캄보디아 141개 군(district), 2017–2020년에 착수한 개발협력 사업 199개(GODAD 지오코딩 자료).

방법의 뼈대. 군마다 '사업이 몇 개 들어왔나'(N)를 세고, 그 숫자를 군의 특성 하나(X)로 설명합니다. 같은 주 안의 군끼리만 비교하고(고정효과), 인구 규모를 맞추며, 개수 자료에 맞는 회귀(PPML)를 씁니다.

발견	숫자	의미
물리적 접근성이 가장 강하다	1SD당 +165%	도로 사정이 한 단계 좋은 군은 사업을 약 2.65배 받는다
빈곤과 오지가 겹친다	단독 -49%(p 0.042) → 도로 통제 시 +92%(n.s.)	가난해서인지 멀어서인지 아직 구분 못 함(센서스로 검정)
사회 분야가 가장 도로에 묶여 있다	사회 +239%, 인프라 -27%	보건·교육 사업일수록 접근성을 따른다
인프라가 원조를 끌어오지 않는다	사건연구 효과 없음	한 번 들어간 곳에 계속 가는 '장소의 지속성'
돈은 패턴이 없다	사업액 -8%(n.s.)	소수 대형 사업이 금액을 좌우

> 이 연구는 Briggs(2021)가 세계은행 직원 설문으로 확인한 "실행이 어려운 곳을 피한다"는 진술을, 실제 사업 입지 자료로 확인한 셈입니다.

1장

출발점: 이미 아는 단순회귀(SLRM)

한 줄 요약

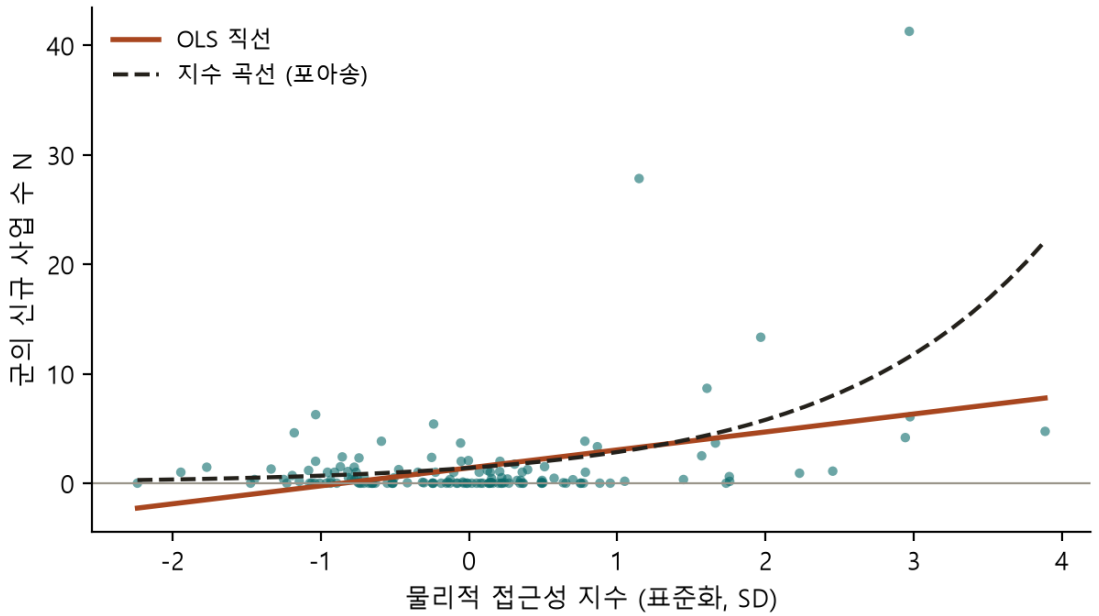
단순회귀는 '**x가 한 단위 늘 때 y가 평균적으로 얼마나 변하나**'를 직선 하나로 요약합니다.

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

기호	뜻	우리 연구에서
y_i	설명하려는 값(종속변수)	군 i의 신규 사업 수 N
x_i	설명하는 값(독립변수)	군 i의 물리적 접근성 지수
β_0	절편: x가 0일 때 y의 평균	평균 수준 접근성인 군의 사업 수
β_1	기울기: x가 1 늘 때 y의 변화	물리적 접근성 한 단계 ↑ → 사업 몇 개 ↑
u_i	오차: 직선이 설명 못 하는 나머지	정치, 우연, 공여기관 사정 등

우리 데이터로 직접 해 보기

141개 군에 단순회귀를 돌리면 **β_1 = 1.64**, 표준오차 0.35, R^2 = 0.14입니다. 읽는 법: 물리적 접근성이 1표준편차 높은 군은 사업이 평균 약 1.6개 더 많다. 군의 평균 사업 수가 1.4개이니 꽤 큰 차이입니다.



그림을 보면 직선(OLS)의 세 가지 문제가 보입니다.

문제	그림에서 보이는 것	해결 (뒤의 장)
① 음수 예측	왼쪽 아래에서 직선이 0 아래로 내려간다. 사업 수는 음수가 될 수 없다.	5장 지수 모형(곡선)은 항상 0 이상

문제	그림에서 보이는 것	해결 (뒤의 장)
② 증가 방식	점들은 오른쪽으로 갈수록 가파르게 늘어난다. 직선은 이를 못 따라간다.	5장: 효과를 '몇 개 더'가 아니라 '몇 배'로
③ 다른 요인	인구가 많은 군, 특정 지역이 섞여 있다.	2장 인구 통제, 3장 같은 주끼리 비교

점선(포아송 지수 곡선)이 점들의 모양을 훨씬 잘 따라가는 것이 보입니다. 이것이 5장의 주인공입니다.

2장

다중회귀: '다른 조건이 같다면'

한 줄 요약

설명변수를 여러 개 넣으면, 각 계수는 **다른 변수를 고정했을 때** 그 변수 하나의 효과가 됩니다.

인구가 많은 군은 사업도 많고 도로도 좋을 수 있습니다. 그러면 단순회귀의 β_1(1.64)에는 '인구가 많아서'의 몫이 섞여 있습니다. 인구(ln Pop)를 함께 넣으면 β_1은 **1.47**로 조금 줄어듭니다. 줄어든 만큼이 인구의 몫이었던 셈입니다.

> **직관:** 다중회귀의 계수 = "인구가 같은 두 군을 비교했을 때, 도로만 다르면 사업이 얼마나 다른가".

왜 인구를 로그(ln)로 넣나

인구는 수천 명에서 수십만 명까지 차이가 큽니다. 로그를 씌우면 '몇 명 더'가 아니라 '몇 % 더'로 비교하게 되어, 큰 군 몇 개가 결과를 좌우하는 것을 막습니다. 5장에서 이 계수(θ)를 '인구 탄력성'으로 읽습니다.

흔한 오해

"변수를 많이 넣을수록 좋다" → 아닙니다. 서로 비슷하게 움직이는 변수를 함께 넣으면 각자의 몫을 가리지 못합니다(8장 다중공선성). 그래서 우리는 기본 분석에서 **모형마다 특성 하나**만 넣었습니다.

3장

고정효과: 같은 주끼리만 비교하기

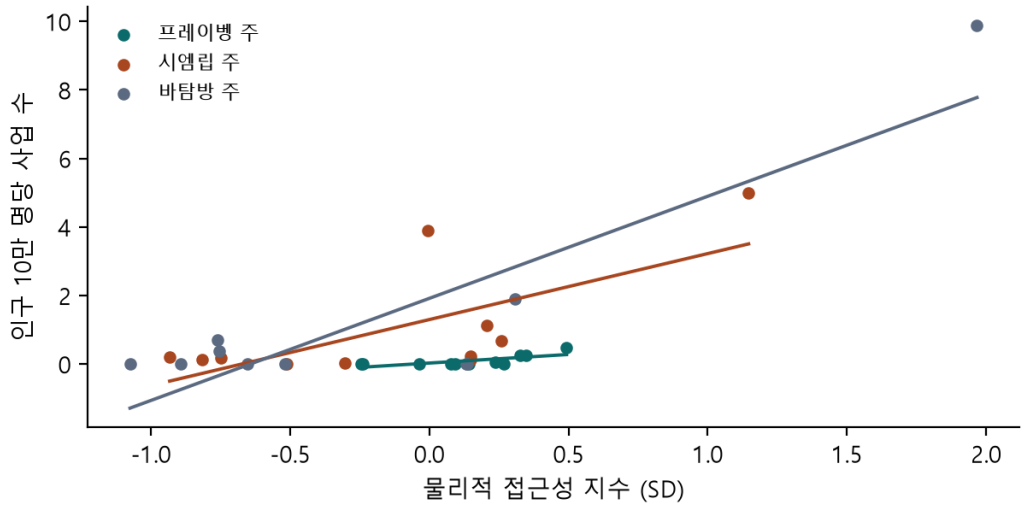
한 줄 요약

주(province) 고정효과는 **주마다 출발점(절편)을 따로 주는 것**입니다. 그러면 비교가 '같은 주 안의 군끼리'로 좁혀집니다.

$$N_d = \alpha_{p(d)} + \beta X_d + \theta \ln \text{Pop}_d + u_d$$

기호	뜻	직관
$\alpha_{p(d)}$	군 d가 속한 주 p의 고정효과(주마다 다른 절편)	주의 정치, 지리, 공여기관 선호 등 '주 전체에 공통인 것'을 모두 흡수
β	같은 주 안에서 X가 1 늘 때 N의 변화	우리가 알고 싶은 값
θ ln Pop_d	인구 규모 통제	큰 군이 많이 받는 것은 당연하니 빼고 본다

그림으로 보기



주마다 점의 높이(출발점)가 다릅니다. 시엠립 주는 전반적으로 높고, 프레이벵 주는 낮습니다. 고정효과는 이 높이 차이를 지우고, **각 주 안에서의 기울기**만 모아서 하나의 β로 만듭니다. 어느 주에서나 오른쪽(도로 좋은 군)으로 갈수록 올라가는 것이 보이죠? 그게 우리가 보는 효과입니다.

우리 숫자

OLS에 주 고정효과를 넣으면 β = **1.86**(사업 개수 기준). 고정효과 모형은 주 더미 변수를 넣은 다중회귀와 같습니다. 주가 21개인데 추정에 실제로 쓰이는 주는 19개입니다. 군이 하나뿐인 주 2개는 '같은 주 안의 비교'가 불가능해 기여하지 않기 때문입니다.

심사자 질문

Q. 고정효과를 왜 주 단위로 넣었나? 군 단위로는 안 되나?

A. 군 고정효과를 넣으면 군마다 절편이 하나씩 생겨 비교할 것이 남지 않습니다(횡단면 자료). 주 고정효과는 주 수준의 정치·지리 요인을 통제하면서 같은 주 안의 비교를 남깁니다.

Q. 주 고정효과가 모든 교란을 없애나?

A. 아닙니다. 주 전체에 공통인 것만 없앱니다. 같은 주 안에서 군마다 다른 정치적 편애 같은 것은 남습니다. 그래서 '인과'가 아니라 '연관'이라고 말합니다.

4장

표준화: '1표준편차당'의 뜻

한 줄 요약

단위가 제각각인 변수(분, Mbps, 불빛 밝기)를 **'평균에서 몇 표준편차 떨어졌나'**라는 같은 잣대로 바꾸는 것입니다.

$$z_d = (x_d - \bar{x}) / s_x$$

z = 0이면 평균인 군, z = +1이면 평균보다 1표준편차 좋은 군, z = -1이면 1표준편차 나쁜 군입니다. 대략 군의 68%가 -1과 +1 사이에 있습니다.

> **그래서 '도로 1SD당 +165%'는** "도로 사정이 평균인 군과, 평균보다 한 단계(1SD) 좋은 군을 비교하면 후자가 사업을 2.65배 받는다"는 뜻입니다.

왜 쓰나: 도로(분), 통신(Mbps), 불빛을 같은 잣대로 놓아야 '어느 것이 더 강한가'를 비교할 수 있습니다.
주의: 표준화해도 '중요도'가 완전히 비교되지는 않습니다. 그래서 9장의 Shapley 분해를 추가로 씁니다.

'주 내부 1SD'는 또 뭔가

사이트 표에 '주 내부 1SD당' 값(+102%)도 있습니다. 같은 주 안에서는 군끼리 차이가 전국 차이보다 작습니다. 고정효과 모형은 같은 주 안의 차이만 쓰므로, '같은 주 안에서 흔히 보는 차이만큼' 다를 때의 효과도 보여 준 것입니다. 더 보수적인 읽기입니다.

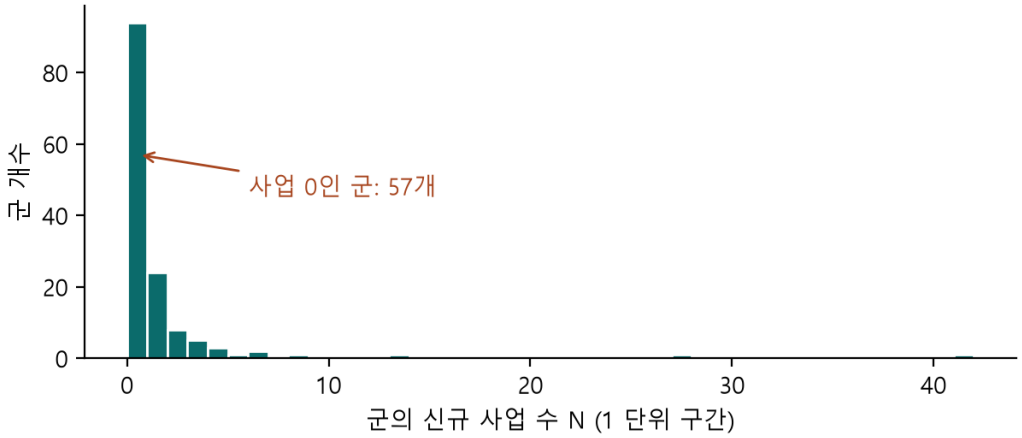
5장

PPML: 개수를 위한 회귀 (이 연구의 핵심 엔진)

한 줄 요약

사업 수 같은 **개수 자료**는 0이 많고 '몇 배'로 늘어나는 성질이 있어서, 직선 대신 **지수 곡선**으로 평균을 설명합니다.

왜 OLS로는 부족한가: 0이 너무 많다



141개 군 중 **57개**가 사업이 하나도 없습니다. 흔히 쓰는 대안인 'log(N)을 종속변수로 한 OLS'는 log(0)이 정의되지 않아 이 군들을 버려야 합니다. 그러면 84개 군만 남고, 하필 사업이 안 간 외딴 군들이 빠집니다. 우리 질문(외딴 곳이 소외되나)에 치명적입니다.

우리 연구의 식

$$\mathbb{E}[N_d] = \exp(\alpha_{p(d)} + \beta X_d + \theta \ln \text{Pop}_d)$$

부분	뜻	직관
$E[N_d]$	군 d에서 기대되는(평균) 사업 수	'평균적으로 몇 개 올까'를 설명한다
exp(…)	괄호 안 값을 지수로 바꿈	결과가 항상 0보다 크고, 효과가 '곱셈'으로 작동
$\alpha_{p(d)}$	주 고정효과	3장과 같다
βX_d	특성 X(예: 도로)의 효과	X가 1 늘면 기대 사업 수가 e^{β}배
$\theta \ln \text{Pop}_d$	인구 탄력성	인구가 1% 늘면 사업이 θ% 는다

계수를 %로 바꾸는 법

$$\%\ \text{change} = 100\,(e^{\beta} - 1)$$

우리 도로 계수는 β = **0.975**입니다. $e^{0.975}$ = 2.65이므로 **100 × (2.65 - 1) = +165%**. 즉 도로가 1SD 좋으면 사업이 약 2.65배입니다.

> **OLS와 PPML의 차이를 한 문장으로**
> OLS: "도로가 1SD 좋으면 사업이 1.9개 **더**" (덧셈)
> PPML: "도로가 1SD 좋으면 사업이 2.65**배**" (곱셈)
> 사업이 0.3개인 외딴 군과 10개인 도시 군에 '+1.9개'를 똑같이 더하는 것보다, '2.65배'가 현실에 훨씬 가깝습니다.

θ (인구 탄력성) 읽기

인구만 넣은 모형에서 θ ≒ 0.46입니다. 인구가 2배인 군은 사업이 $2^{0.46}$ ≒ 1.4배입니다. θ가 1이면 사업이 인구에 정비례, 1보다 작으면 **작은 군이 1인당 더 많이** 받는다는 뜻입니다.

'PPML'이라는 이름의 뜻

Poisson Pseudo-Maximum Likelihood. 포아송 분포의 계산법을 빌려 쓰지만, 자료가 정말 포아송 분포일 필요는 없고 **평균의 식(위의 exp 식)만 맞으면** 계수가 올바르게 추정된다는 뜻에서 'pseudo(유사)'가 붙습니다(Santos Silva & Tenreyro 2006). 그래서 정수가 아닌 값(우리 N은 여러 군에 걸친 사업을 1/K씩 나눠 소수점이 있음)에도 쓸 수 있습니다.

심사자 질문

Q. 왜 음이항(negative binomial) 회귀가 아니라 PPML인가?

A. PPML은 평균 식만 맞으면 일관된 추정치를 주고, 분산 가정이 틀려도 견고합니다. 음이항 결과도 강건성 점검으로 보고했고 +145%로 비슷합니다.

Q. 0이 많은데 zero-inflated 모형을 써야 하지 않나?

A. PPML은 0을 그대로 포함해 다룹니다. '사업 유무'와 '개수'를 나눠 보는 hurdle 모형(주 고정효과 없이)도 점검했습니다. 도로는 사업이 '있느냐'보다(승산비 1.29, p 0.19) '있다면 몇 개냐'에서 차이가 뚜렷합니다(+75%, p 0.002).

6장

표준오차와 p값, 그리고 '군집' 문제

복습

표준오차는 '같은 연구를 다른 표본으로 반복하면 계수가 얼마나 흔들릴까'의 크기입니다. **p값**은 '진짜 효과가 0인데도 이 정도 결과가 우연히 나올 확률'입니다. 보통 0.05보다 작으면 유의하다고 합니다.

군집(cluster)이란

같은 주의 군들은 서로 닮았습니다(같은 주정부, 비슷한 지리, 같은 공여기관 사무소). 그러면 141개 군이 141개의 독립된 정보가 아닙니다. 이를 무시하면 표준오차가 실제보다 작게 나와 **과신**하게 됩니다. 군집 표준오차는 '같은 주끼리는 한 덩어리'로 보고 계산합니다.

> **비유:** 141명에게 설문했는데 사실 21가족이 함께 답했다면, 독립된 의견은 141개가 아니라 21개에 가깝습니다.

우리의 걱정: 덩어리가 너무 적다

주가 약 20개뿐이면 군집 표준오차조차 불안정할 수 있습니다. 그래서 다음 장의 세 가지(+1) 방법을 함께 쓰고, **그중 가장 나쁜(가장 큰) p값을 채택**한다는 규칙을 결과를 보기 전에 정해 두었습니다.

7장

결과가 우연이 아님을 확인하는 네 가지 방법

방법	무엇을 하나 (비유)	물리적 접근성 p
① 주 군집 표준오차	같은 주 군들을 한 덩어리로 보고 오차 계산	0.001
② Conley 공간 표준오차	주 경계와 무관하게, 50·100km 안의 가까운 군끼리 서로 닮을 수 있다고 보고 계산	< 0.001
③ 무작위화 추론 (Freedman–Lane)	같은 주 안에서 도로 값을 군끼리 무작위로 섞은 '가짜 세계'를 2,000번 만들어, 실제 결과가 얼마나 특이한지 본다	0.002
→ 사전 규칙: 가장 큰 p 채택		**0.002**
④ Wild cluster bootstrap (추가)	주 단위로 동전을 뒤집어 1만 번 가짜 세계를 만든다. 엄격한 버전 / 느슨한 버전	0.077 / < 0.001

③ 무작위화 추론을 더 쉽게

만약 도로와 사업이 정말 아무 관계가 없다면, 같은 주 안에서 어느 군에 어떤 도로 값이 붙어 있든 상관없어야 합니다. 그래서 도로 값을 섞어서 2,000번 다시 추정해 봅니다. 섞은 결과 중 실제 계수만큼 큰 경우가 0.2%뿐이면 p = 0.002입니다. 분포 가정이 거의 필요 없어 소표본에서 믿을 만합니다.

④ Wild bootstrap 결과를 정직하게 읽기

엄격한 버전에서 도로 효과가 p = 0.077로 경계선이 나왔습니다. 원인은 시엠립과 코콩·시아누크빌 두 주가 계산상 흔들림의 78%를 만들기 때문입니다. 이런 상황에서 엄격한 버전은 지나치게 보수적이고, 느슨한 버전은 너무 관대합니다.

점검	결과
두 주를 모두 빼고 추정	+147% (p < 0.001)
시엠립만 빼면 / 코콩만 빼면	+107% / +217% (두 주는 반대 방향으로 당김)
주별로 따로 보면	17개 주 중 14개에서 같은 방향 (p = 0.013)

> **한 문장으로:** 효과의 방향과 크기는 어떤 점검에서도 견고하고, 특정 주에 기대지 않는다. 다만 가장 엄격한 소표본 추론에서는 '거의 확실' 수준(p = 0.077)이다.

8장

다중공선성과 경합(horse race) 모형

한 줄 요약

두 설명변수가 거의 항상 같이 움직이면, 회귀는 **누가 한 일인지 구분하지 못합니다.**

> **비유:** 두 친구가 늘 함께 다니며 함께 일하면, 일이 잘됐을 때 누구 덕인지 알 수 없습니다. 캄보디아에서 '가난한 군'과 '외딴 군'이 그렇습니다(상관 -0.84).

경합 모형: 모든 요인을 한꺼번에

요인 (1SD당)	4요인 모형 효과	군집 p	가장 보수적인 p	VIF
야간 불빛	+85%	0.001	0.095	1.1
물리적 접근성	+81%	< 0.001	0.064	1.1
디지털 접근성 (모바일 속도)	+50%	< 0.001	0.205	1.0
이전 인프라	+83%	0.067	0.394	1.2
네 요인 결합 검정	유사 R^2 0.41 → 0.69	< 0.001	0.002	

읽는 법. 네 추정치 모두 양(+)이고 단일 모형과 크기가 비슷합니다. 군집 표준오차로는 대부분 유의하지만, **가장 보수적인 p로는 하나도 5%를 넘지 못합니다.** 반면 **결합 검정**(네 계수가 모두 0인가?)은 p = 0.002로 분명히 기각됩니다.

> **결합 검정이란?** 개별 검정은 '다른 셋을 고정했을 때 이것 하나만의 효과가 0인가'를 묻고, 결합 검정은 '넷 다 0인가'를 한 번에 묻습니다. 축구로 치면 '공격수 A 덕인가 B 덕인가'는 가리기 어려워도 '공격진이 득점에 기여했는가'는 분명히 답할 수 있는 것과 같습니다.

VIF(분산팽창계수, 다른 변수와 겹치는 정도)가 1.0–1.2로 낮으므로, 개별 유의성이 약해진 것은 다중공선성 때문이 아니라 19개 주 안에서 섞는 무작위화 추론이 엄격하기 때문입니다. 반면 빈곤을 넣은 5요인 모형은 도로 +631%, 빈곤 +259%처럼 계수가 비현실적으로 부풉니다(빈곤 VIF 5.1). 이것이 진짜 다중공선성의 증상이라, 5요인 모형은 해석하지 않습니다.

그래서 빈곤에 대해 무엇을 말할 수 있나

모형	빈곤 1SD당	해석
빈곤만	-49% (가장 보수적 p 0.042)	가난한 군은 사업을 덜 받는다
빈곤 + 도로	+92% (군집 p 0.38)	도로를 고정하면 빈곤 계수가 0과 구별되지 않는다

결론: "가난해서가 아니라 멀어서 덜 받는다"와 맞는 결과입니다. 하지만 두 변수가 너무 겹쳐서 이 자료만으로는 확정할 수 없고, 그래서 출처가 다른 센서스 박탈 지수로 다시 검정합니다(사전등록 H-C1).

9장

Shapley 분해: 설명력을 공정하게 나누기

계수는 단위와 겹침 때문에 '누가 더 중요한가'를 바로 말해 주지 않습니다. Shapley 값은 **팀 프로젝트 기여도 평가**와 같은 원리입니다.

$$\phi_j = \text{average over orderings of } [v(S \cup \{j\}) - v(S)]$$

다섯 요인을 모형에 넣는 순서는 5! = 120가지입니다. 각 순서마다 '이 요인이 들어올 때 설명력(유사 R^2)이 얼마나 늘었나'를 기록하고 평균합니다. 먼저 들어오면 공을 많이 가져가고 나중에 들어오면 적게 가져가는 불공정을 순서 평균으로 없앱니다.

요인	도로	빈곤	야간 불빛	모바일	이전 인프라
설명력 몫	**39%**	20%	16%	16%	9%

다섯 요인이 인구·주 외에 추가로 설명하는 몫은 유사 R^2 34.1%p이고, 그중 39%가 도로 몫입니다. 빈곤과 도로가 겹치는 부분은 둘이 나눠 가집니다.

10장

물리적 접근성 지수: 10개 지표를 하나로

만드는 과정 4단계

① 2017년 OSM 도로 구간마다 속도를 정한다(도로 등급, 포장, 경사, 우기). ② 1km 격자 214,537개마다 도시·군청·병원까지 최단 이동시간을 계산한다. ③ 인구 가중 평균으로 군 단위 값을 만든다. ④ 10개 지표를 표준화해 **주성분분석(PCA)**의 가중치로 합친다.

$$S_d = \sum_{k=1}^{10} w_k z_{dk}$$

PCA 직관: 10개 지표가 대부분 같은 방향(접근성 좋음↔나쁨)으로 움직입니다. PCA는 그 공통 방향을 찾아, 각 지표가 그 방향을 얼마나 잘 대표하는지에 따라 가중치(w)를 줍니다. 제1주성분이 10개 지표 변동의 61%를 담습니다. 이동시간 지표들이 가중치 0.37–0.39로 가장 크고, 2017년 지도에 포장 정보가 적어 포장 비율은 거의 0입니다.

계산 예시: 두 군

	Krong Battambang (주도)	Andoung Meas–Koun Mom (라타나끼리 농촌)
인구 2만+ 도시까지 (건기)	14.8분	285분
도로까지 도보	3분	41분
가중합 S	4.77	-1.76
지수 (S ÷ 2.475)	**+1.93**	**-0.71**

두 군의 차이는 약 2.64SD입니다. 모형으로 환산하면 $e^{0.975 \times 2.64} \fallingdotseq$ **13배**의 사업 수 차이입니다(인구와 주가 같다면).

민감도: 가중치를 같게 하거나, 지표를 하나씩 빼거나, 속도 가정을 바꾸는 등 20가지로 지수를 다시 만들어도 효과는 +131%~+177%입니다.

11장

사건연구: 인프라가 원조를 끌어오나

한 줄 요약

어떤 일(첫 교통·에너지 사업)이 일어나기 **전과 후**를, 그 일을 겪지 않은 비교 집단과 견주어 보는 방법입니다.

$$\mathbb{E}[N_{dt}] = \exp(\mu_d + \lambda_t + \sum_{k \neq -1} \beta_k \mathbf{1}[t - g_d = k])$$

기호	뜻
μ_d	군 고정효과: 원래 사업이 많은 군인지 아닌지를 흡수
λ_t	연도 고정효과: 그해 전국적으로 사업이 많았는지 흡수
$1[t - g_d = k]$	첫 인프라 사업 후 k년째인지 표시 (k = -5 … +4, 직전 해 -1이 기준)
β_k	k년째에 처치 군이 비교 군보다 사업이 몇 % 더 많은가

읽는 법. 처치 전($k < 0$)의 β가 0 근처면 두 집단이 원래 비슷했다는 뜻이고(사전 추세 검정 $p = 0.35$), 처치 후($k \geq 0$)의 β가 올라가면 인프라가 사업을 끌어왔다는 뜻입니다. 우리 결과: 처치 후에도 올라가지 않았고, 오히려 음수 쪽(평균 -45%, 유의하지 않음).

> **주의:** "효과가 없다"가 아니라 "**효과의 증거가 없다**"입니다. 처치 군이 41개뿐이라 작은 효과는 못 잡을 수 있습니다.

'누적(stacked)'은 첫 인프라 시점이 다른 군들을 시점별 코호트로 나눠, 각 코호트를 자기 비교 군과만 비교한 뒤 쌓는 방식입니다(Cengiz et al. 2019). 시점이 제각각일 때 생기는 비교 오류를 피합니다.

12–13장

경계 분석, 민감도, 투 트랙

지오코딩 경계 분석

위치를 군 단위까지 못 찾은 사업 49개는 접근성 낮은 주에 몰려 있습니다. 이들이 실제로 어디 있었는지에 따라 결과가 달라질 수 있으니, 극단을 가정해 봅니다.

가정	도로 효과
관측(군 단위 위치만)	+165%
현실적 가정들 (인구 비례 분배, 설명 충실 사업만 등)	+123% ~ +199%
최악: 전부 주에서 가장 외딴 군에 있었다면	+68% (p 0.063)
최선: 전부 가장 연결 좋은 군에 있었다면	+237%

투 트랙: 사업 수 vs 사업액

같은 모형을 금액(약정액)에 적용하면 도로 효과는 -8%로 패턴이 없습니다. 상위 5개 대형 사업이 금액의 65%를 차지해 금액을 좌우하기 때문입니다. **해석:** 접근성은 '사업을 어디에 여나'를 좌우하지만 '돈을 어디에 쏟나'는 소수 대형 사업이 정합니다.

14장

심사자 질문 12개와 답변

Q. 이건 인과 효과인가?

A. 아닙니다. 같은 주 안에서의 연관입니다. 도로가 사업을 '끌어온다'고 주장하지 않고, 사업이 도로를 따라 놓인다는 패턴을 보입니다. 인과를 주장하지 않는 대신 측정 시점(2017년 도로망, 2015년 불빛)을 사업 이전으로 맞췄습니다.

Q. 도로가 좋은 곳은 원래 부유한 곳 아닌가?

A. 그래서 야간 불빛(경제활동)과 빈곤을 따로 측정해 경쟁시켰습니다. 4요인 모형에서 도로는 +81%로 크기는 유지되지만, 가장 보수적인 p는 0.064라 다른 요인과 떼어 놓고 단정할 수는 없습니다. 네 요인의 결합 검정은 p = 0.002입니다.

Q. 빈곤과 도로를 구분할 수 있나?

A. 현재 자료로는 상관(-0.84)이 너무 높아 확정할 수 없습니다. 출처가 다른 센서스 박탈 지수로 검정할 계획이고, 그 방법은 자료를 보기 전에 사전등록했습니다.

Q. 왜 OLS가 아니라 PPML인가?

A. 0이 57개인 개수 자료에서 log-OLS는 그 군들을 버려야 하고, OLS는 음수를 예측합니다. PPML은 0을 포함하고 효과를 배수로 읽습니다.

Q. 주가 20개뿐인데 표준오차를 믿을 수 있나?

A. 군집, Conley, 무작위화 추론 세 가지 중 가장 보수적인 p를 미리 정해 썼고(0.002), wild bootstrap도 추가로 공개했습니다(엄격한 버전 0.077). 두 주를 빼도 +147%, 17개 주 중 14개가 같은 방향입니다.

Q. 지오코딩이 외딴 곳을 놓쳐서 생긴 결과 아닌가?

A. 실제로 위치 미상 사업이 외딴 주에 몰려 있습니다. 그래서 경계 분석으로 범위(+123%~+199%, 극단 +68%)를 보고합니다. 설명이 충실해 위치가 정확한 사업에서 효과가 오히려 더 큽니다.

Q. 물리적 접근성 지수는 임의로 만든 것 아닌가?

A. 20가지 다른 구성에서도 +131%~+177%로 결과가 같습니다.

Q. GODAD가 원조의 33%만 담는데 대표성이 있나?

A. 결론의 범위를 '캄보디아 원조의 약 3분의 1과 중국'으로 명시합니다. 일본·ADB·한국은 빠져 있습니다.

Q. 인프라 사업이 이후 원조를 끌어오지 않나?

A. 사건연구에서 그런 증거가 없습니다. 대신 원래 사업이 많던 곳에 계속 몰리는 장소의 지속성이 보입니다.

Q. 디지털 접근성 효과는?

A. +80%로 양의 연관이 있지만 무작위화 추론 p = 0.060으로 확증되지 않았습니다. 군 단위 속도는 반기간 신뢰도가 0.52로 잡음이 크고, 측정 밀도 같은 이용 지표는 물리적 접근성과 구분되지 않습니다. 그래서 탐색적 결과로 두고, 센서스 휴대전화 보급률을 주 지표로 다시 검정합니다.

Q. 사업 정의를 중간에 바꾼 것 아닌가?

A. 네, 같은 사업이 CRS에 여러 번 기록된 것을 발견해 활동 단위로 바꿨고, 명세서에 사후 수정으로 기록했습니다. 기존 정의 결과도 함께 보고하며, 결론은 같습니다.

Q. AI를 어떻게 썼나?

A. 연구 질문·설계 원칙은 연구자가 정했고, 코드·추정·글 작성에 AI를 썼습니다. 모든 결과는 공개 코드로 재현되며, AI는 저자가 아니라 방법론에 사용 내역을 밝힙니다.

15장

3주 학습 계획과 자가 점검

주	공부할 장	목표
1주	0–5장	β, 고정효과, 1SD, +165%를 남에게 설명할 수 있다
2주	6–9장	p값 네 가지와 가장 보수적인 규칙, 다중공선성을 설명할 수 있다
3주	10–14장	지수, 사건연구, 경계 분석을 설명하고 심사자 질문에 답할 수 있다

보조 교재(무료 온라인): Nick Huntington-Klein, The Effect (고정효과·사건연구 장), Scott Cunningham, Causal Inference: The Mixtape.

자가 점검 문제

1. β = 0.975인 PPML 계수를 %로 바꾸면?

2. 주 고정효과를 넣으면 무엇과 무엇을 비교하게 되나?

3. log(N)을 쓴 OLS의 가장 큰 문제는?

4. θ = 0.46이면 인구가 2배인 군의 사업은?

5. 무작위화 추론 p = 0.002는 무슨 뜻?

6. 빈곤 계수가 도로를 넣자 -49%에서 +92%로 바뀐 이유는?

7. 4요인 모형에서 개별 p는 모두 0.05를 넘는데 결합 검정은 0.002인 이유는?

8. 사건연구에서 사전 추세 검정 p = 0.35가 의미하는 것은?

9. '효과가 없다'와 '효과의 증거가 없다'의 차이는?

정답

1. $100 \times (e^{0.975} - 1) \fallingdotseq +165\%$
2. 같은 주 안의 군끼리
3. 사업 0인 군 57개를 버려야 한다
4. $2^{0.46} \fallingdotseq 1.4$배. 작은 군이 1인당 더 받는다
5. 섞은 가짜 세계 2,000개 중 실제만큼 큰 결과가 0.2%뿐
6. 두 변수가 강하게 겹치는(다중공선성) 상황에서 빈곤의 몫이 도로로 넘어갔기 때문
7. 네 요인이 함께는 분명히 설명하지만, 19개 주로는 각자의 몫을 가장 엄격한 기준에서 가리기 어렵기 때문
8. 처치 전에는 두 집단이 다르지 않았다. 비교가 타당하다는 근거
9. 후자는 표본이 작아 작은 효과를 못 잡았을 가능성을 열어 둔다

16장

용어집

용어	한 줄 뜻
OLS / SLRM	직선으로 평균 관계를 요약하는 회귀 / 설명변수가 하나인 회귀
고정효과	집단(주)마다 절편을 따로 둬서 집단 안의 비교만 남기는 것
표준화(1SD)	평균에서 몇 표준편차 떨어졌는지로 단위를 통일
PPML	개수 자료의 평균을 지수 식으로 설명하는 회귀. 0 포함, 효과는 배수
인구 탄력성 θ	인구가 1% 늘 때 사업이 몇 % 느는가
군집 표준오차	같은 집단 관측치가 서로 닮은 것을 반영한 표준오차
Conley 표준오차	가까운 지역끼리 닮은 것을 거리 기준으로 반영
무작위화 추론	설명변수를 섞은 가짜 세계와 비교해 p값을 구함
Wild cluster bootstrap	군집 단위로 부호를 뒤집어 가짜 세계를 만드는 소표본 보정
Holm 보정	여러 가설을 동시에 검정할 때 우연히 유의할 확률을 보정
MDE	이 표본으로 검출할 수 있는 최소 효과 크기
다중공선성 / VIF	설명변수끼리 겹침 / 겹침 정도의 지표
유사 R^2	비선형 모형에서 설명력을 나타내는 R^2 비슷한 지표
Shapley 값	설명력을 모든 투입 순서에 걸쳐 평균 기여로 나눈 것
주성분분석(PCA)	여러 지표의 공통 방향을 찾아 하나로 합치는 방법
사건연구	사건 전후를 비교 집단과 견주어 효과를 보는 방법
사전 추세	처치 전 두 집단의 차이. 없어야 비교가 타당
경계 분석	모르는 부분에 극단 가정을 넣어 결과의 범위를 구함
사전등록	자료를 보기 전에 분석 계획을 공개해 고정하는 것